Task 1

Oleg Chaban

1 этап

Считываем данных из training.csv.

```
dates_rows<-read.csv("training.csv", header = TRUE, row.names = 1)
dates_rows.ts<-ts(dates_rows, start=c(1959,1), frequency=12)
```

Построим скользящие статистики - скользящее среднее и стандартное отклонение.

```
dates_rows_rl<-rollmean(dates_rows.ts, 5)
dates_rows_d<-((dates_rows_rl-dates_rows.ts)^2/359)^(1/2)
```

Строим график, на котором отрисованны сам ряд и его скользящие статистики. Скользящее среднее окрашено оранжевым цветом, стандартное отклонение - зеленым.

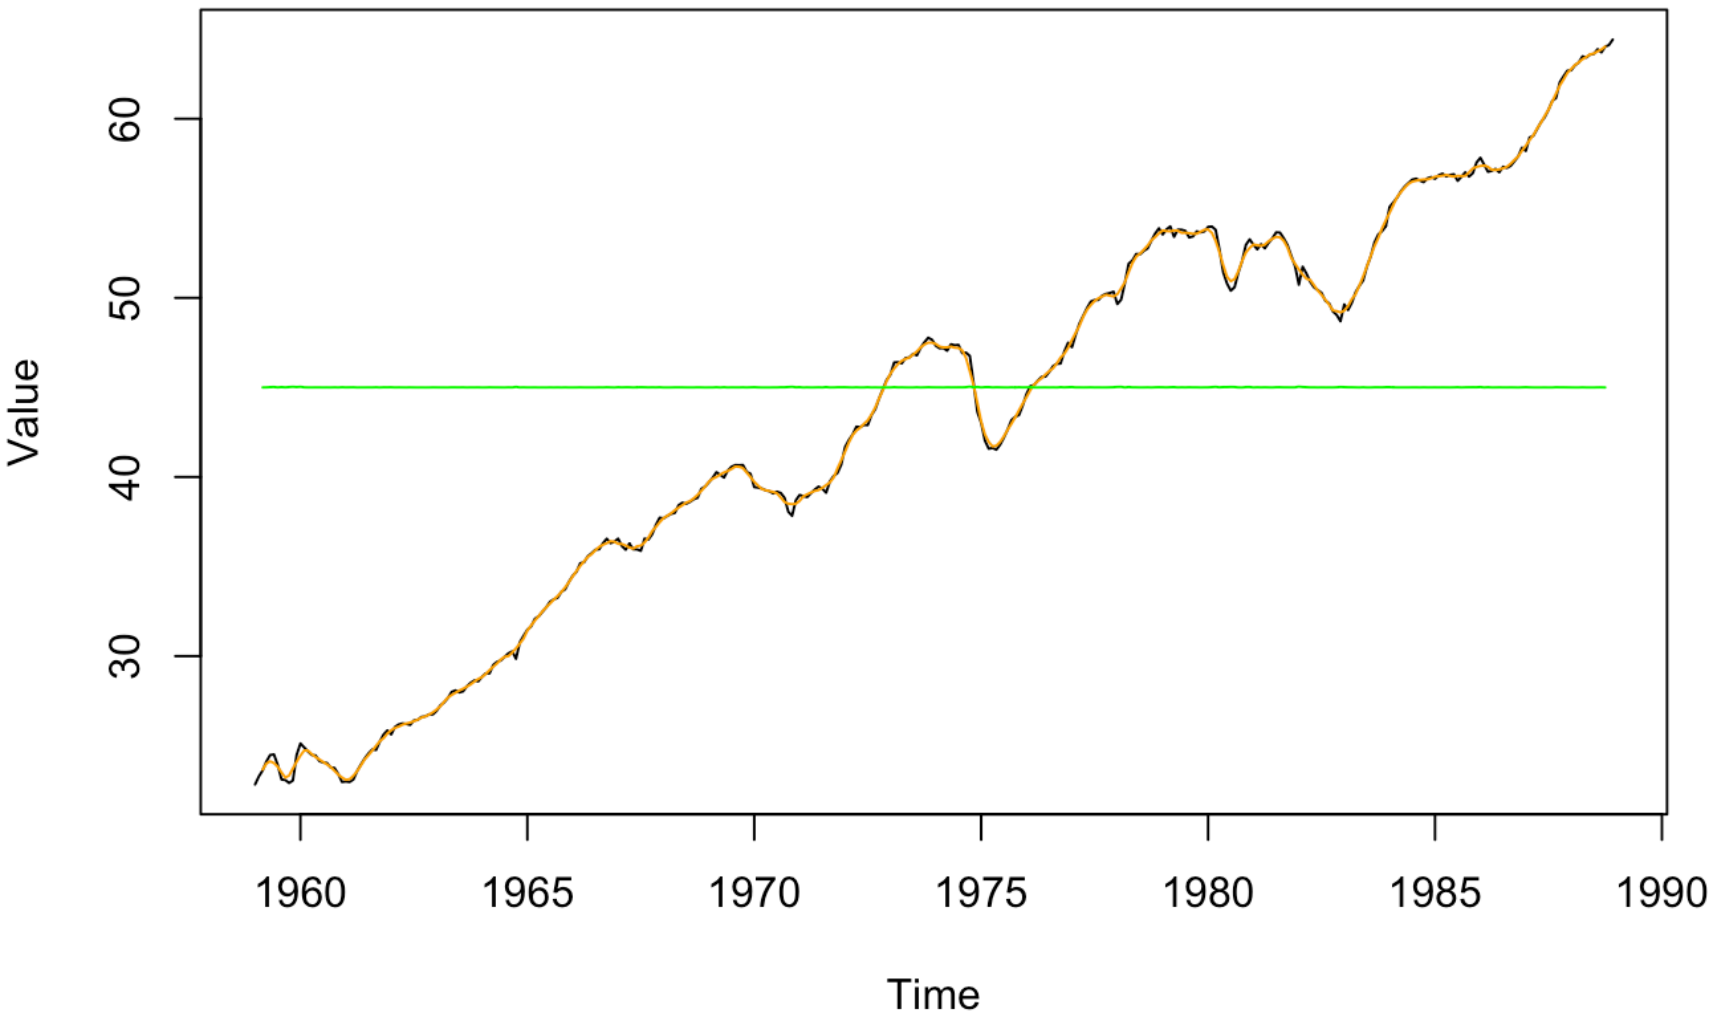

Изучив данные графики, можно сказать, что что ряд является нестационарным.

Проведем тест Дики-Фуллера.

```
adf.test(dates_rows.ts)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  dates_rows.ts
## Dickey-Fuller = -3.2505, Lag order = 7, p-value = 0.07962
## alternative hypothesis: stationary
```

Так как корень один, то можно считать, что ряд нестационарен. В результате, после проведения двух тестов, можно сказать, что исходный ряд является нестационарным.

2 этап

Расскладываем временной ряд на тренд, сезональность, остаток в соответствии с аддитивной, мультипликативной моделями.

```
dates_rows_add<-decompose(dates_rows.ts,type = "additive")
dates_rows_mul<-decompose(dates_rows.ts,type = "multiplicative")
```

Построим графики.

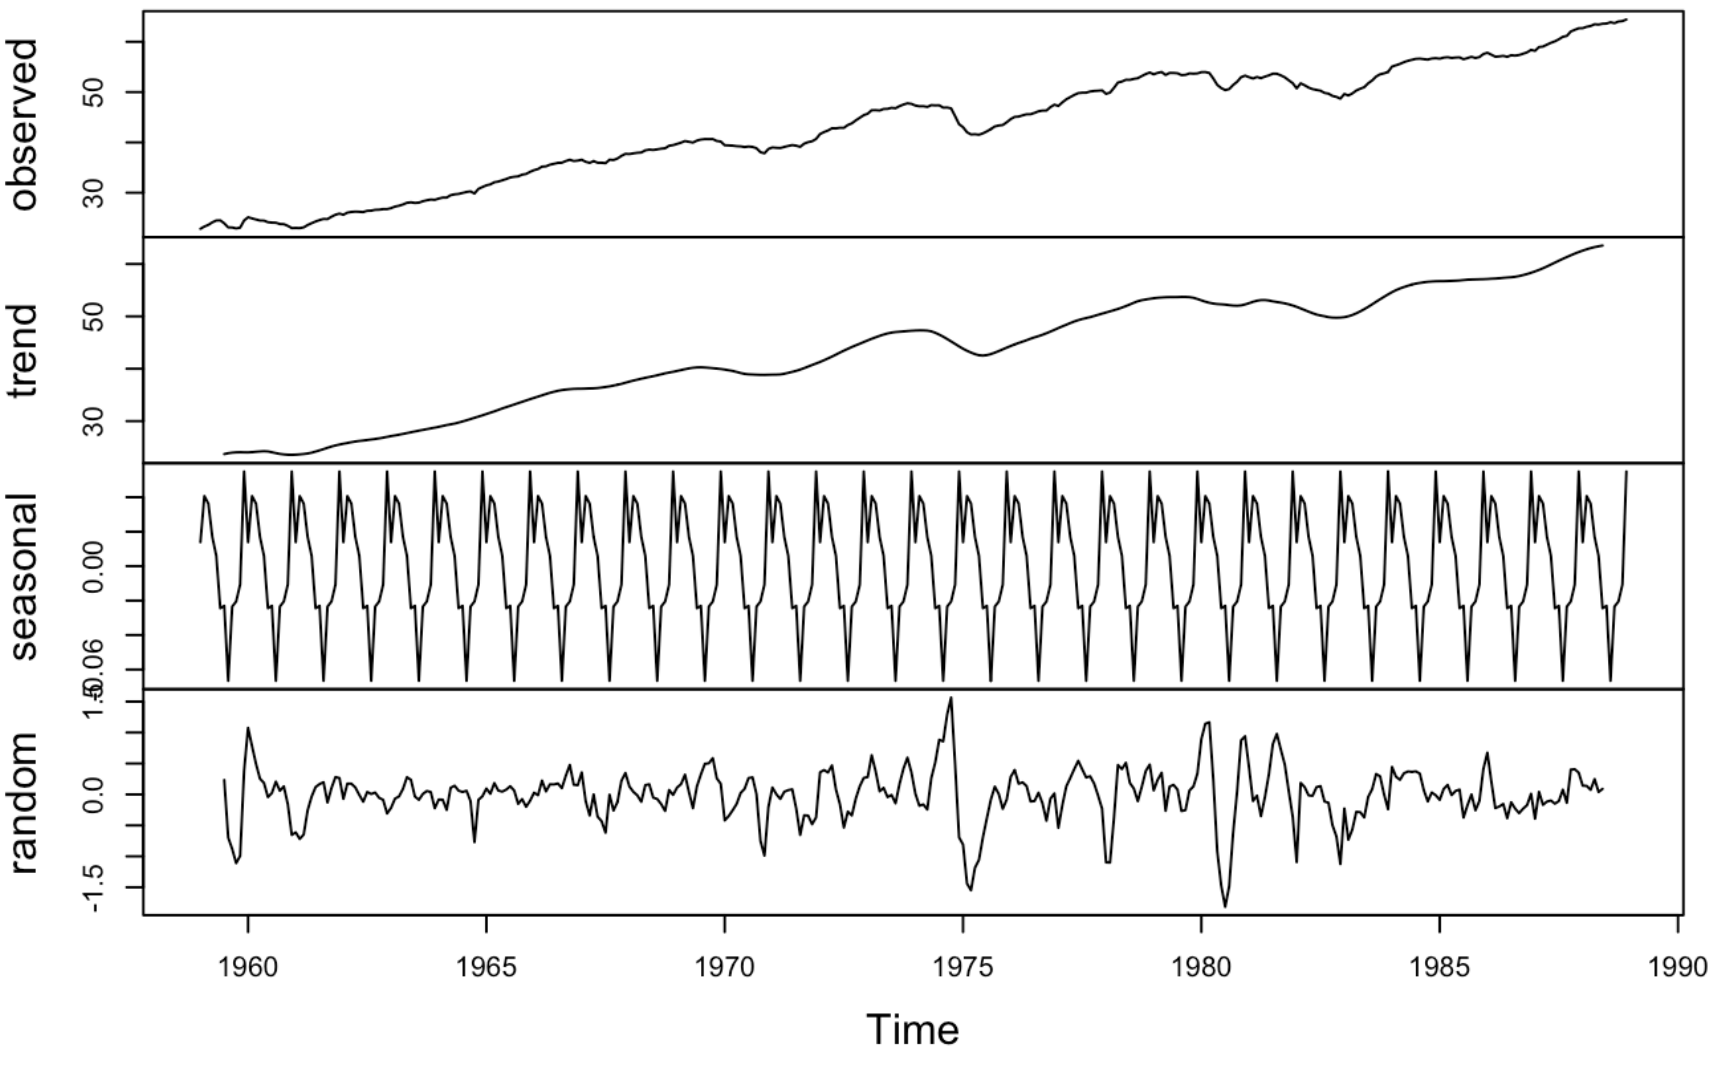
Decomposition of additive time series
observed
trend
seasonal
random
30
50
0.00
0.06
1.5
0.0
-1.5
1960
1965
1970
1975
1980
1985
1990
Time

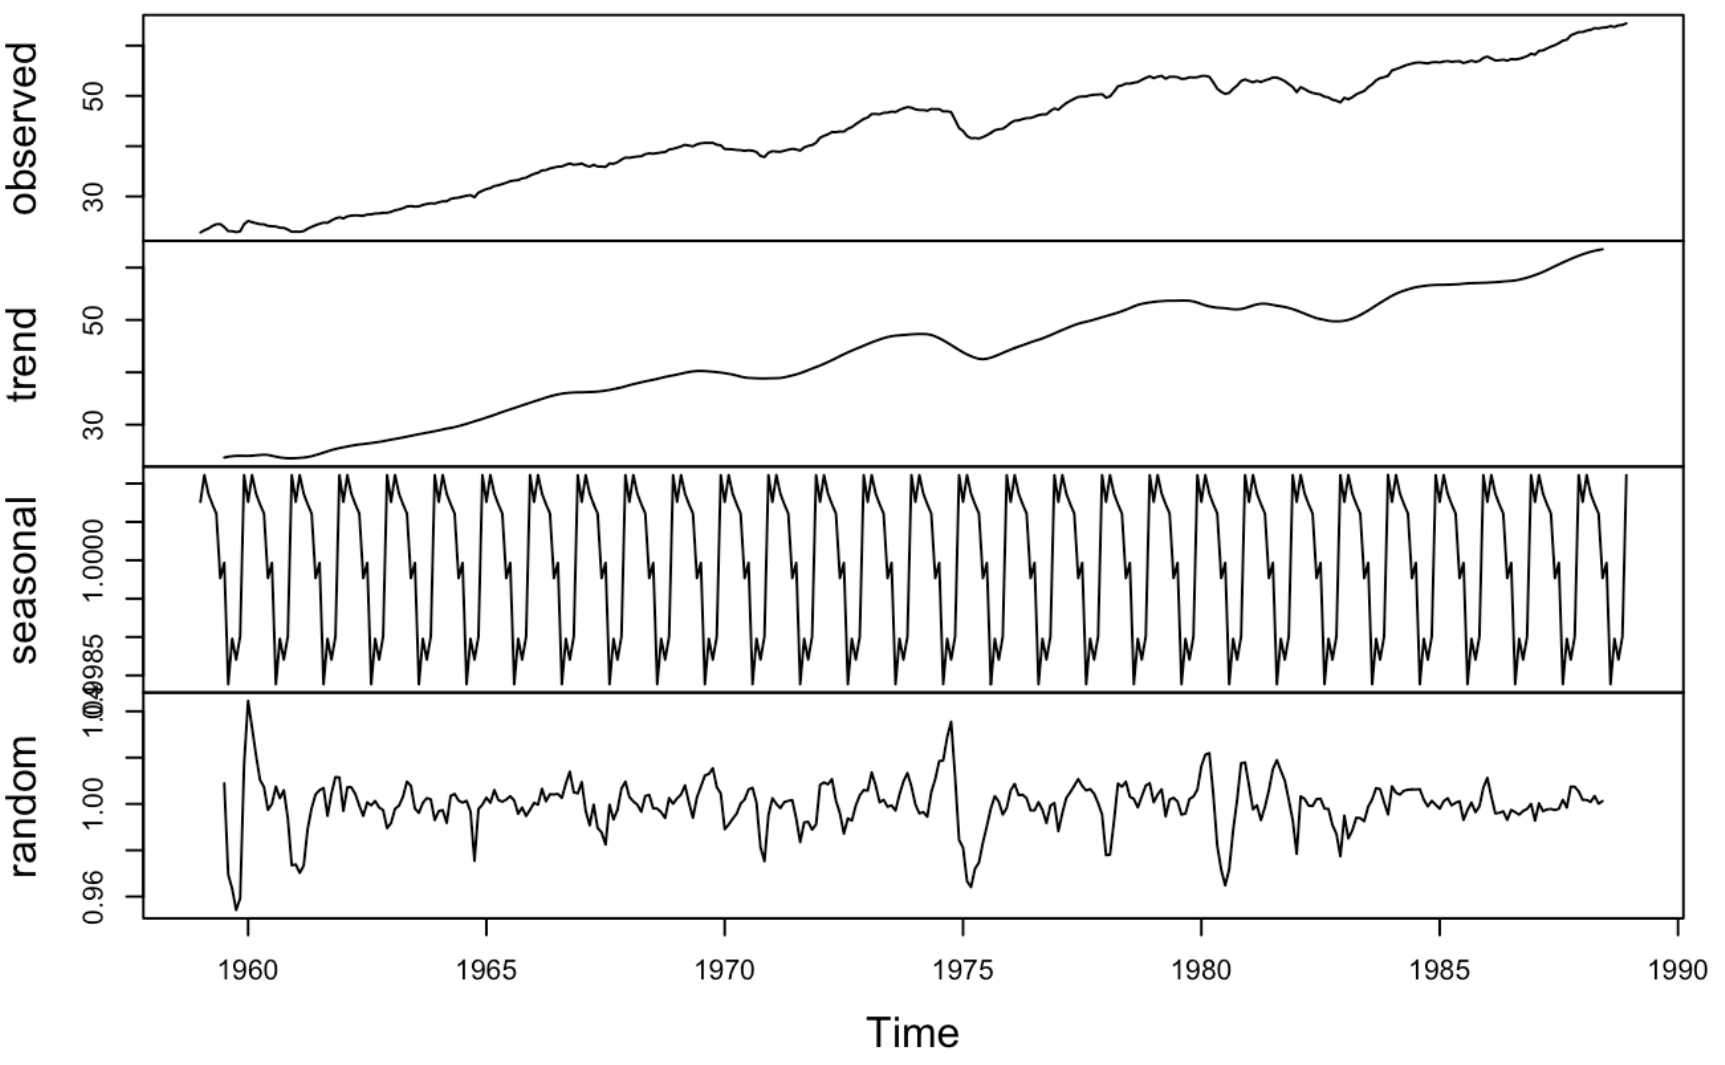
Decomposition of multiplicative time series
observed
trend
seasonal
random
30
50
1.0000
0.9985
1.04
1.00
0.96
1960
1965
1970
1975
1980
1985
1990
Time

В обеих моделях видно, что тренд не стационарен, но сезональность и остаток - стационарны в широком смысле, т.к. статистические характеристики не изменяются с течением времени. Чтобы удостовериться в этом, проведем тест Дики-Фуллера.

```
adf.test(na.remove(dates_rows_add$seasonal), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_add$seasonal)
## Dickey-Fuller = -10.169, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

```
adf.test(na.remove(dates_rows_add$trend), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_add$trend)
## Dickey-Fuller = -0.6874, Lag order = 0, p-value = 0.9711
## alternative hypothesis: stationary
```

```
adf.test(na.remove(dates_rows_add$random), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_add$random)
## Dickey-Fuller = -7.3949, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

```
adf.test(na.remove(dates_rows_mul$seasonal), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_mul$seasonal)
## Dickey-Fuller = -9.192, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

```
adf.test(na.remove(dates_rows_mul$trend), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_mul$trend)
## Dickey-Fuller = -0.6874, Lag order = 0, p-value = 0.9711
## alternative hypothesis: stationary
```

```
adf.test(na.remove(dates_rows_mul$random), k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  na.remove(dates_rows_mul$random)
## Dickey-Fuller = -7.5842, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

Наше предположение верно. В обеих моделях значение параметра p-value у тренда большое, следовательно, ряд не является стационарным. А для остатка и сезональности он мал, что подтверждает их стационарность.

3 этап

Проанализируем последовательно разности временного ряда, для того, чтобы определить порядок интегрированности этого ряда.

```
diff_n<-diff(dates_rows.ts, differences=1)
plot.ts(diff_n)
```

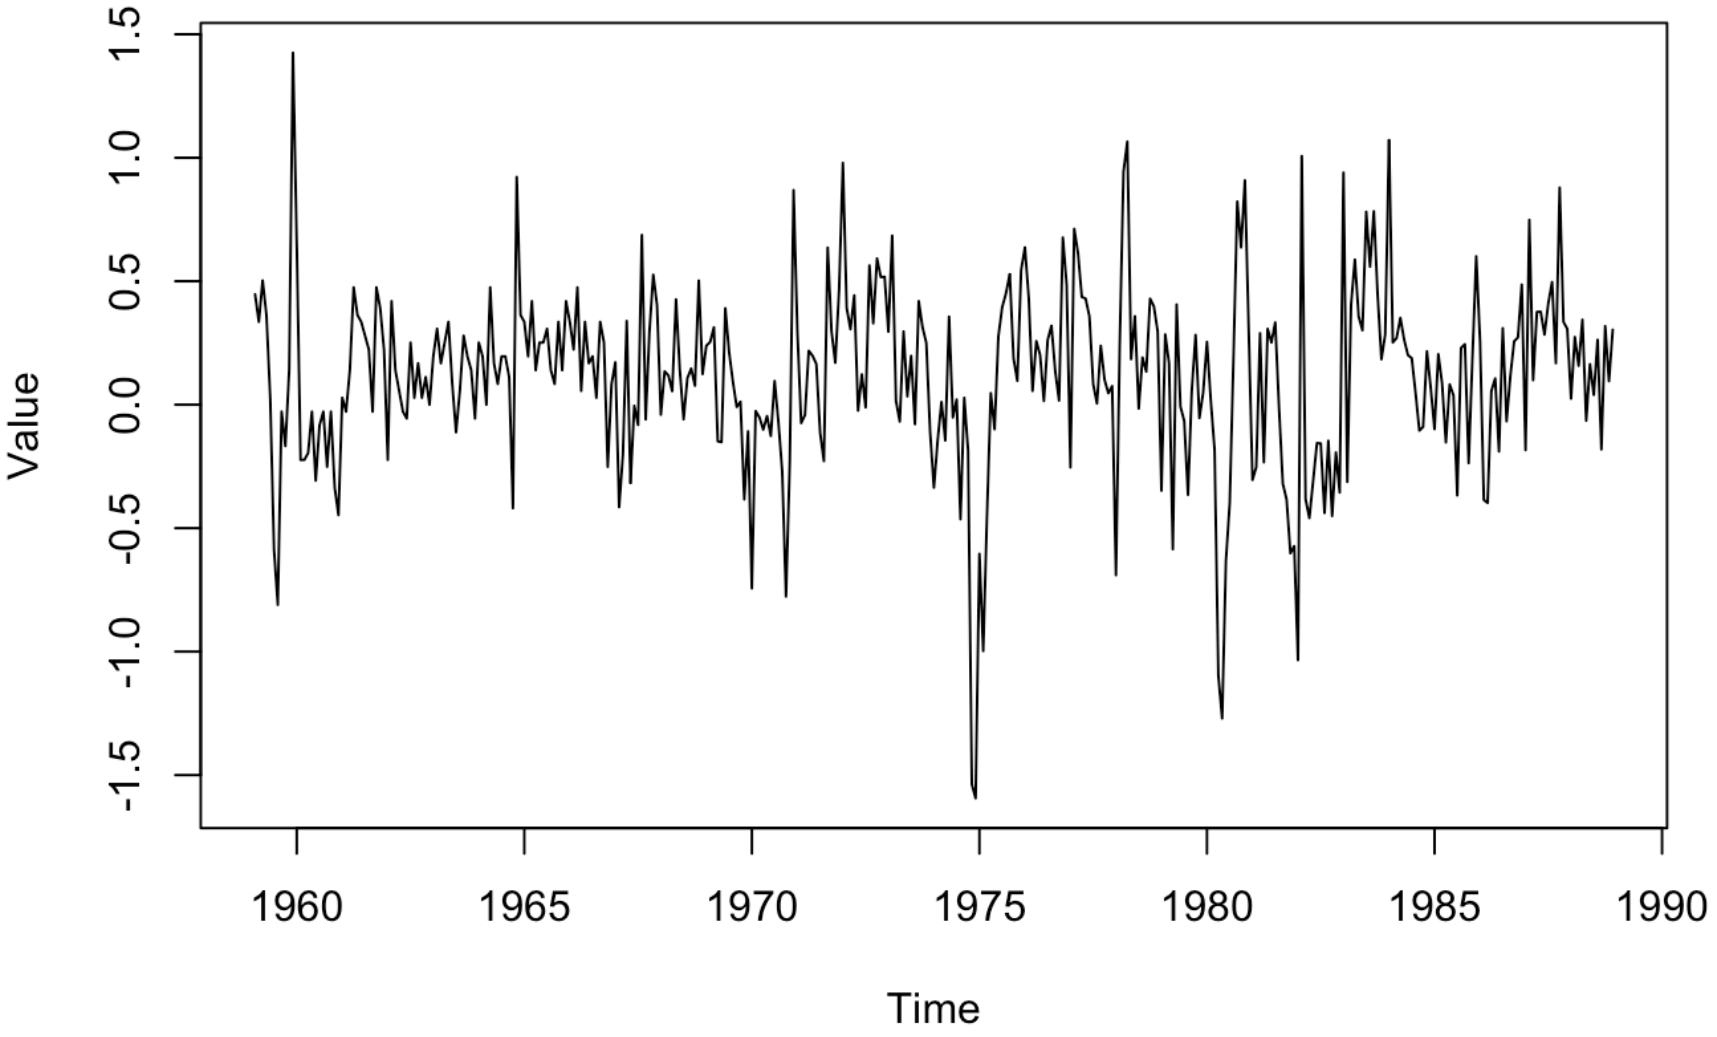


```
adf.test(diff_n, k = 0)
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  diff_n
## Dickey-Fuller = -12.2, Lag order = 0, p-value = 0.01
## alternative hypothesis: stationary
```

Из результатов теста Дики-Фуллера можно сделать вывод, что порядок интегрированности равен 1, т.к. первая разность исходного ряда - стационарна.

Построим функции автокоррелеации и частичной автокоррелеации

```
acf(diff_n,main="Автокоррелеация")
```

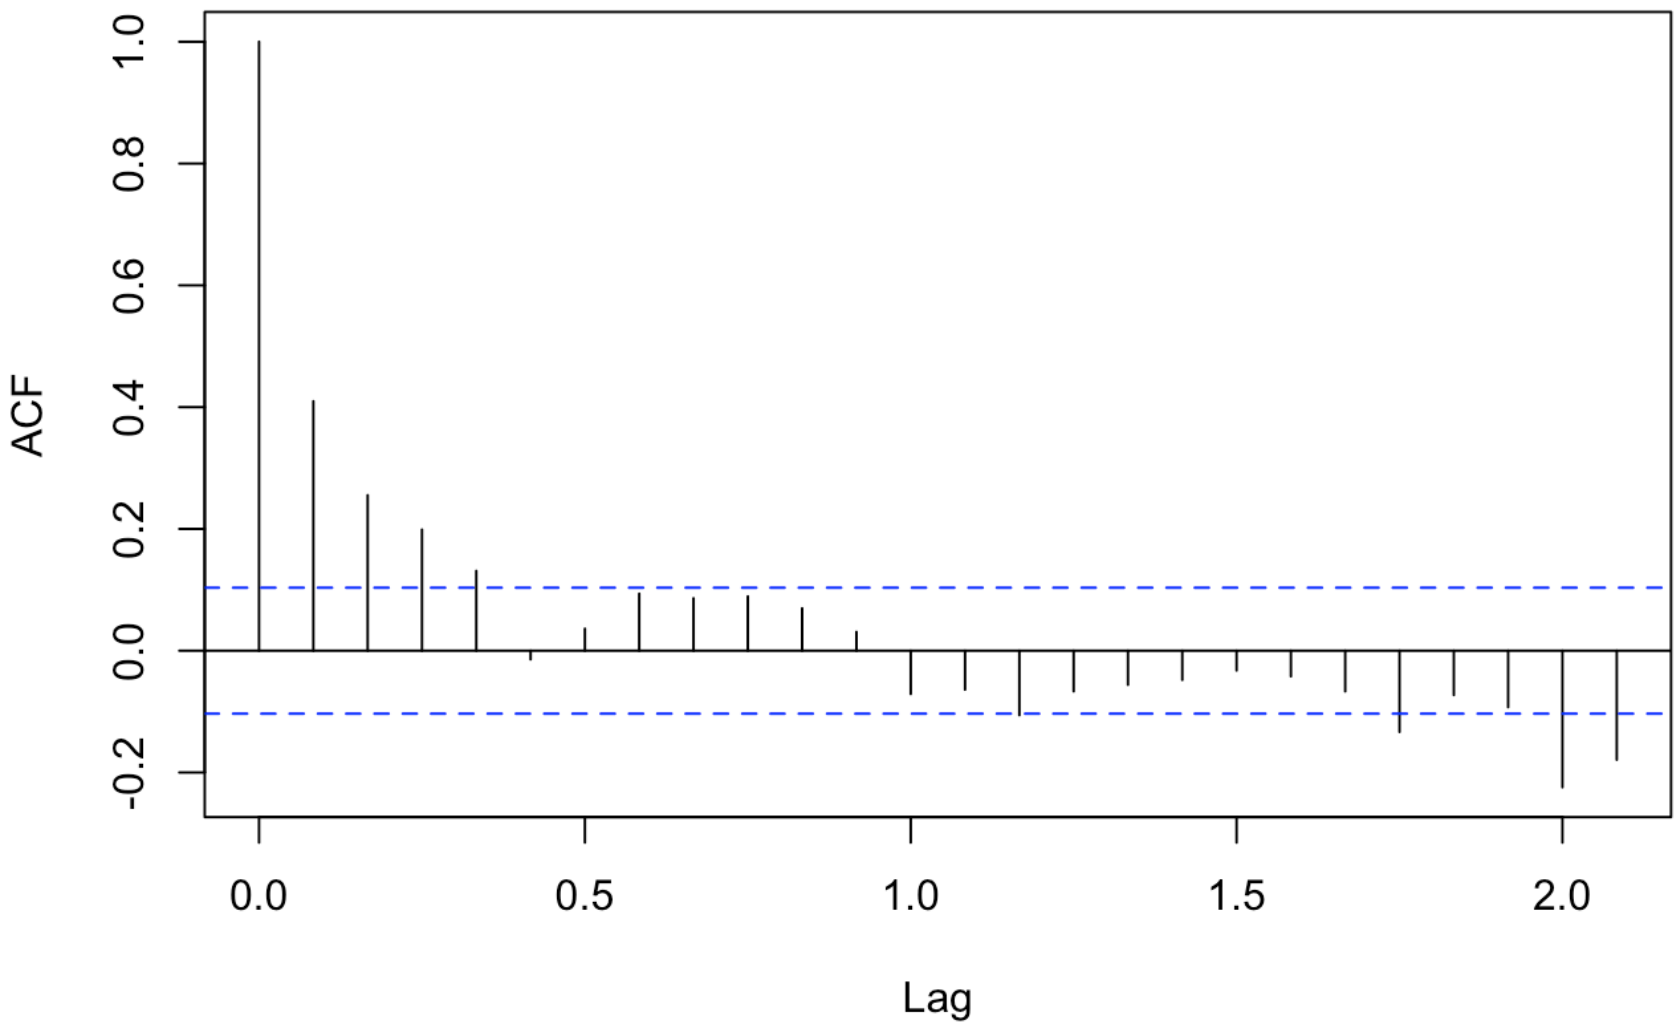


```
pacf(diff_n,main="Частичная автокоррелеация")
```

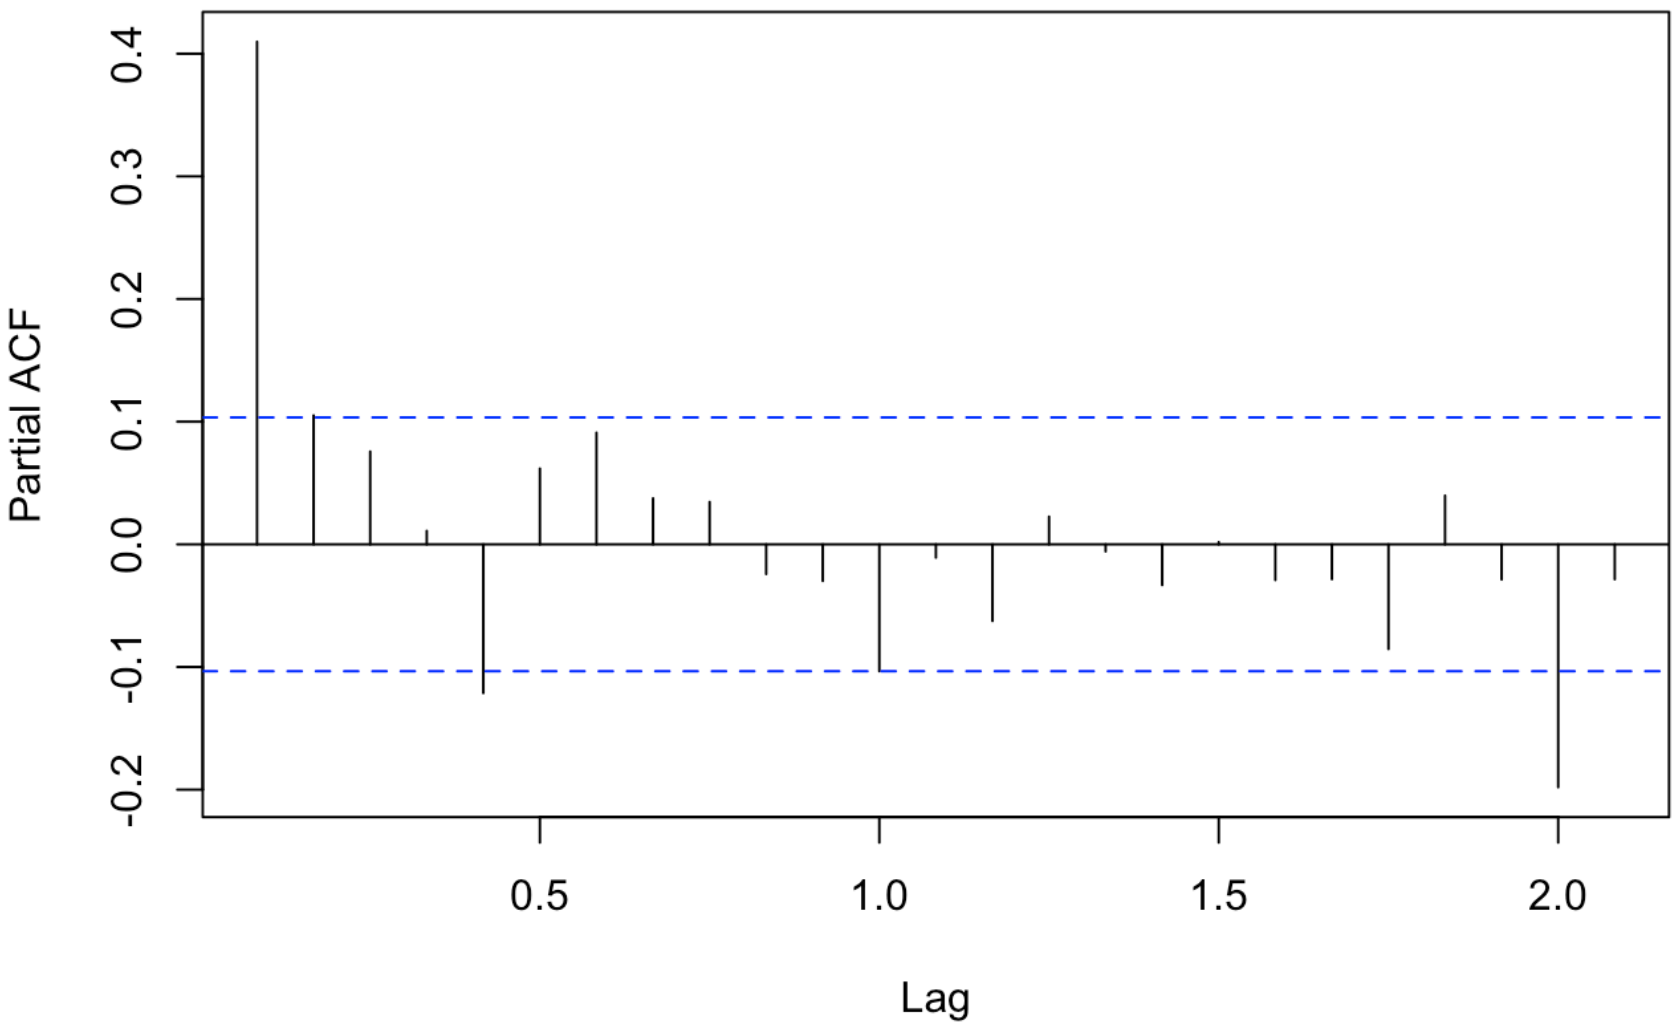

С помощью pacf и acf находим параметры p и q для построения моделей ARIMA. Параметр d равен порядку интегрированного ряда. Потроим несколько моделей ARIMA с параметрами, выбранными таким образом, что: 0<=p<=2, d=1, 0<=q<=4.

```
model01<-Arima(dates_rows.ts,order=c(2,1,0))
model02<-Arima(dates_rows.ts,order=c(0,1,4))
model03<-Arima(dates_rows.ts,order=c(2,1,4))
model04<-Arima(dates_rows.ts,order=c(1,1,1))
```

Считываем данные из testing.csv.

```
test<-read.csv("testing.csv",header=TRUE, row.names = 1)
test.ts<-ts(test, start=c(1989,1), frequency=12)
```

Вычисляем для каждой модели прогноз с помощью forecast.Arima.Так же проверяем, что для каждого прогноза значение r2_score достаточно близко к нулю. Визуализируем forecast.Arima для всех моделей.

```
frcst_1<-forecast.Arima(model01,h=60)
R2_Score(frcst_1$mean,test.ts)
```

```
## [1] -0.08292902
```

```
plot.forecast(frcst_1)
```

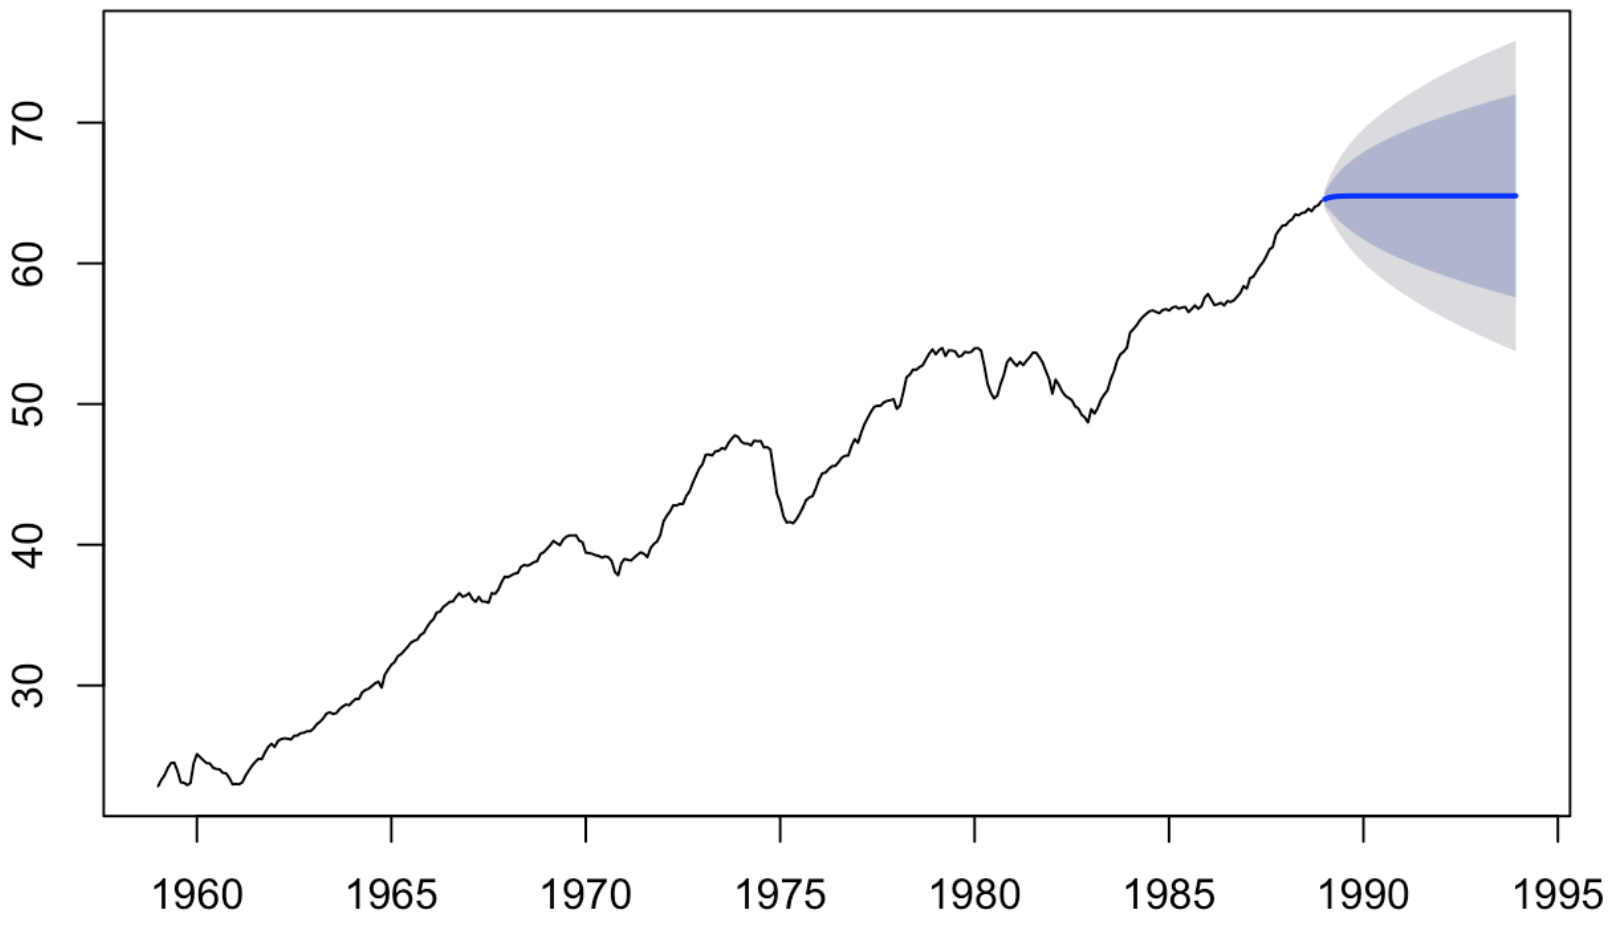


```
frcst_2<-forecast.Arima(model02,h=60)
R2_Score(frcst_2$mean,test.ts)
```

```
## [1] -0.09951206
```

```
plot.forecast(frcst_2)
```

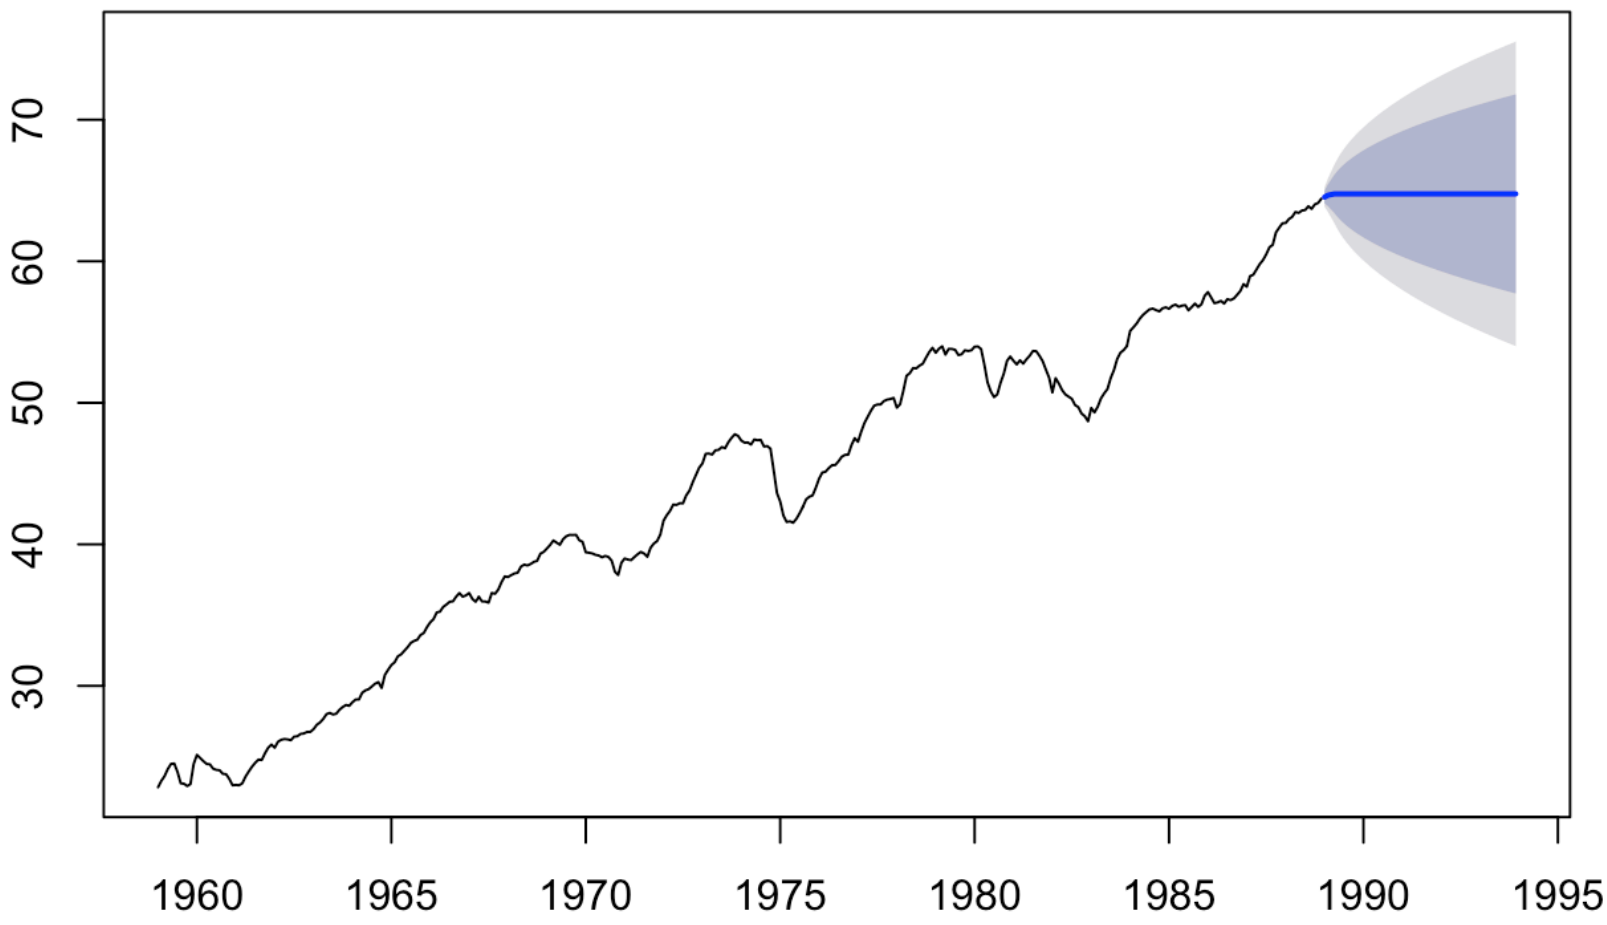


```
frcst_3<-forecast.Arima(model03,h=60)
R2_Score(frcst_3$mean,test.ts)
```

```
## [1] -0.104477
```

```
plot.forecast(frcst_3)
```

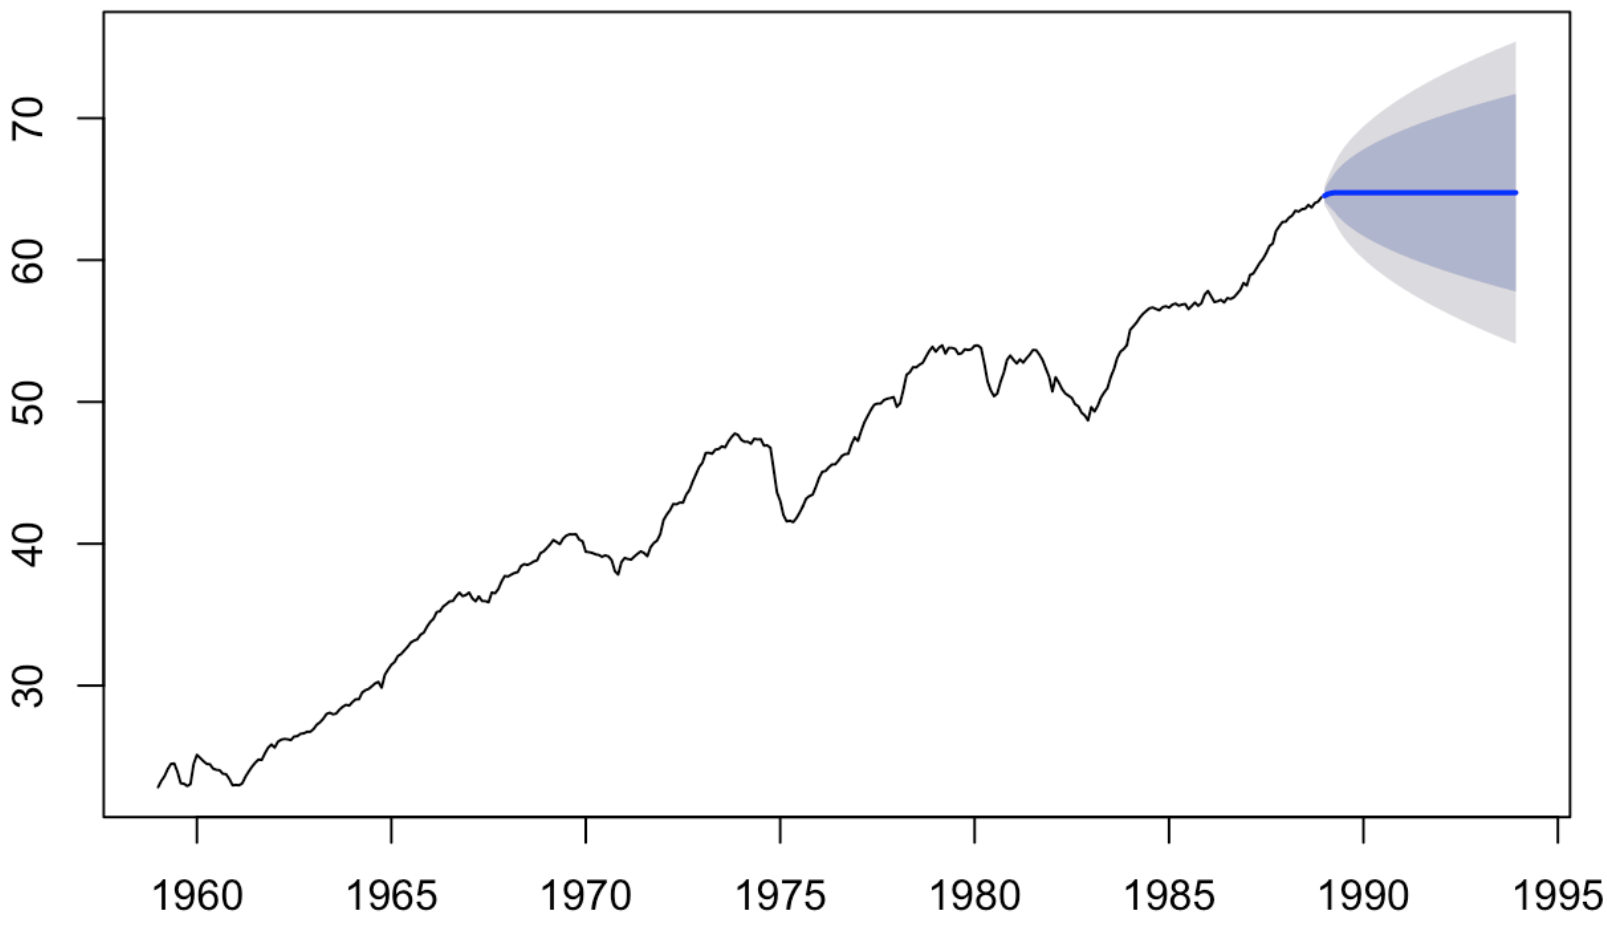


```
frcst_4<-forecast.Arima(model04,h=60)
R2_Score(frcst_4$mean,test.ts)
```

```
## [1] -0.02447902
```

```
plot.forecast(frcst_4)
```

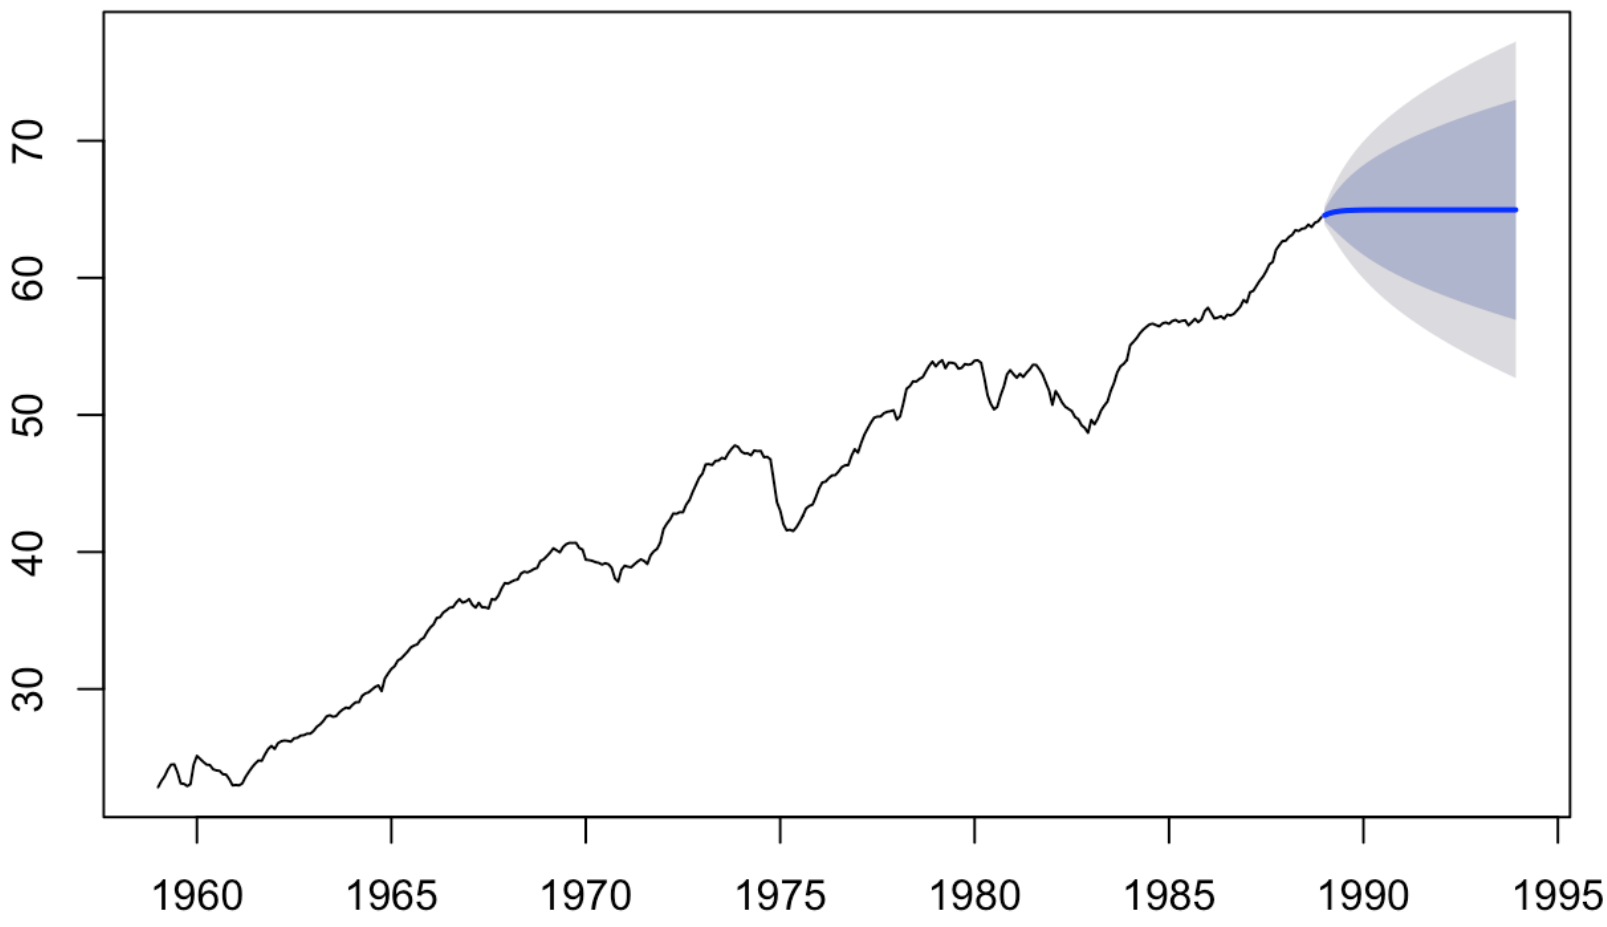

С помощью информационного критерия Акаике(AIC) из всех этих моделей находим наилучшую: выбираем модель с минимальным значением критерия AIC.

```
AIC(model01,model02,model03,model04)
```

```
##          df      AIC
## model01  3 258.5099
## model02  5 253.3399
## model03  7 257.3009
## model04  3 255.6413
```

Визуализируем forecast.Arima выбранной модели и получаем область прогноза дальнейших значений временного ряда. Строим график тестовой выборки.

```
plot.forecast(frcst_2)
lines(test.ts,col='green')
```

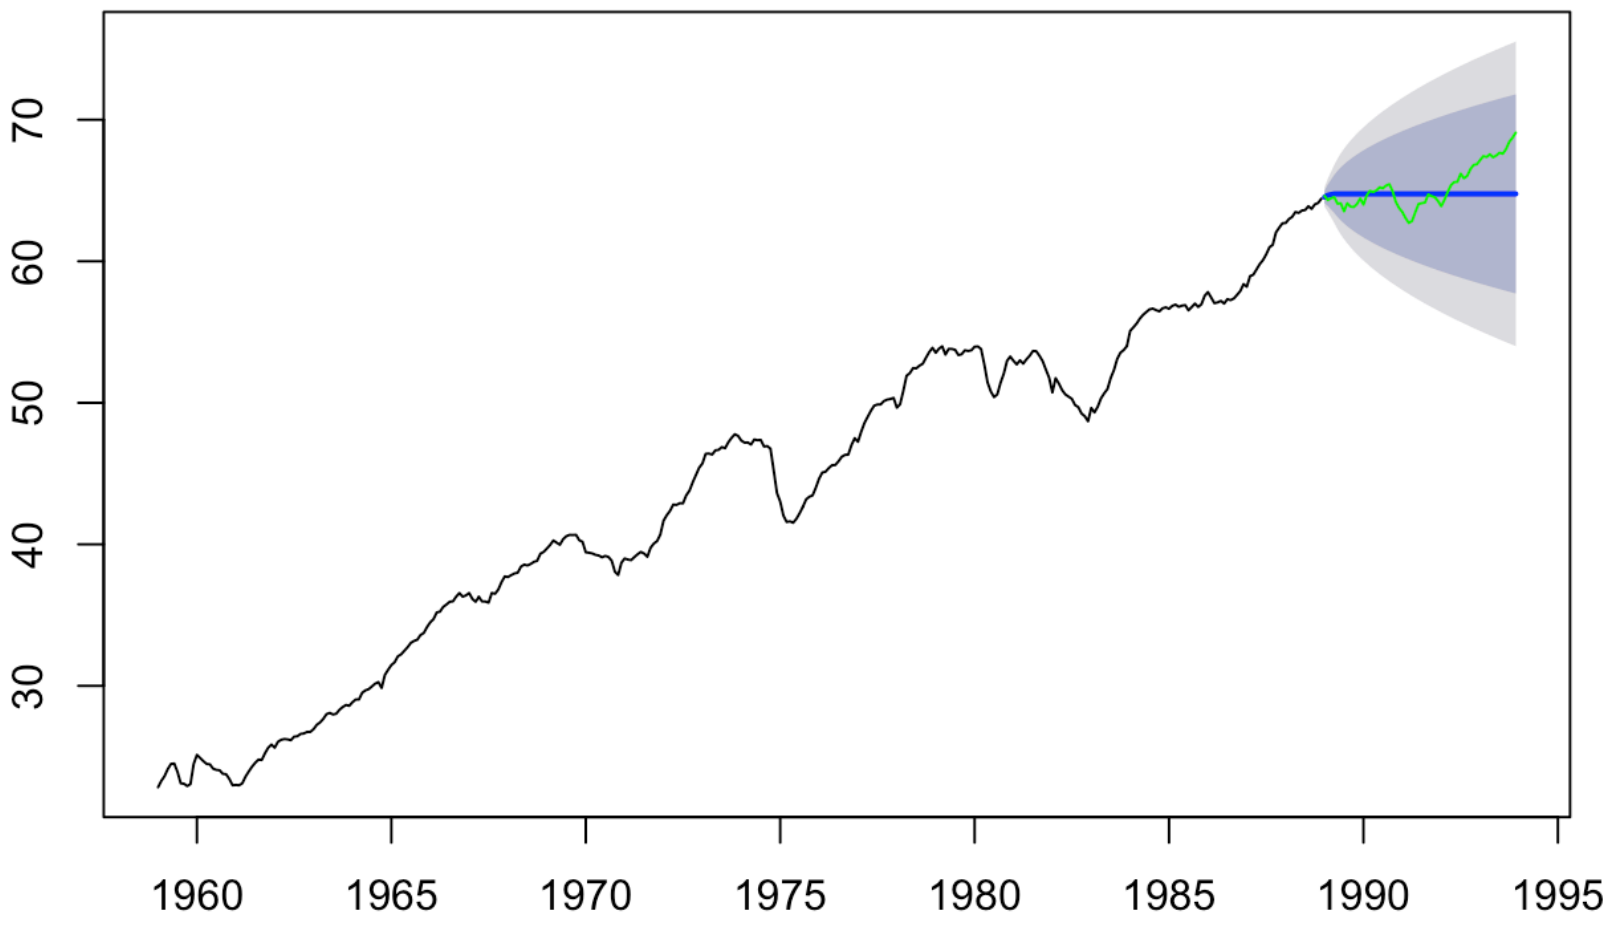

Мы убедиись, что график лежит внутри спрогнозируемой области. Получается, что нами был построен верный прогноз.